INFORME DE EVALUACIÓN CRÍTICA

Proyecto SOLARIS - FrescaMar S.A.S.

Módulo 4: validación, interpretabilidad, sesgos, riesgos e impacto ético

Autora: Ana Sofía Herrera Sánchez
Fecha: octubre de 2026

Recomendación ejecutiva: DESPLEGAR CON CONDICIONES, únicamente como sistema de apoyo a la decisión y no como decisor autónomo.

Resumen ejecutivo

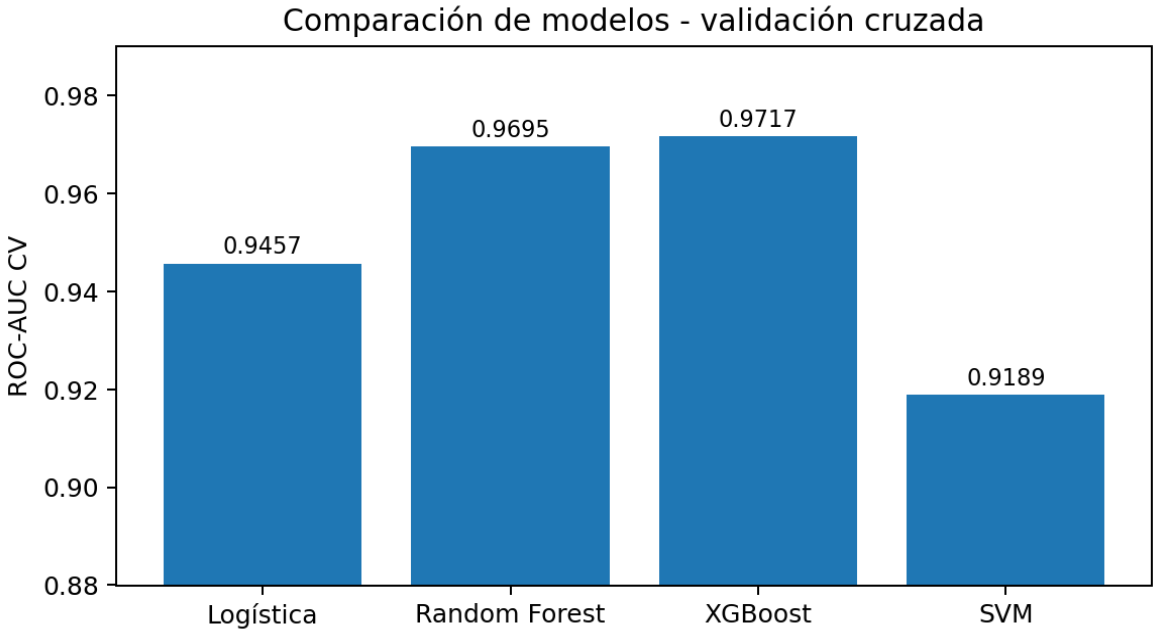
SOLARIS estima el riesgo de mora de distribuidores de FrescaMar S.A.S. El pipeline final usa Random Forest con preprocesamiento integrado, split estratificado 80/20 y random_state=42. En prueba alcanza ROC-AUC 0.9588, Accuracy 0.9362, Precision Moroso 0.9076, Recall Moroso 0.6278 y F1 0.7422. La brecha ROC-AUC train-test es 0.0391, lo que no activa la alerta interna de 0.10. No obstante, el recall queda por debajo del objetivo de negocio de 0.75, por lo que el modelo todavía deja pasar una fracción importante de morosos reales.

La auditoría de equidad no detecta alertas en Demographic Parity ni brechas de AUC superiores a 0.05, pero Equalized Odds muestra diferencias de sensibilidad: 18.78 p.p. por edad, 12.48 p.p. por educación y 25.33 p.p. por ciudad. SHAP confirma que saldo_actual, cuotas_pagadas y score_externo dominan la decisión. El modelo puede aportar valor como herramienta de priorización si se ajusta el umbral con validación interna, se revisa la disparidad geográfica, se documenta score_externo y se mantiene supervisión humana.

1. Validación técnica robusta

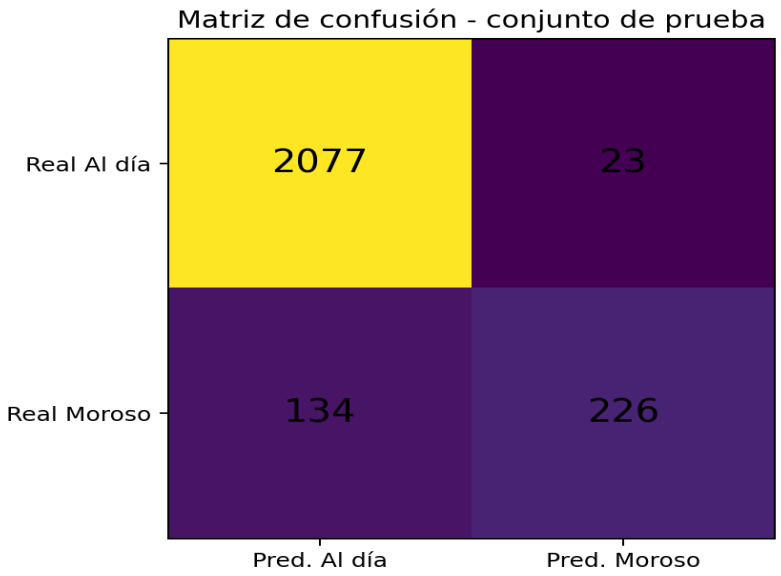
Las métricas operativas se reportan sobre el conjunto de prueba (2.460 registros), aislado del entrenamiento. La validación cruzada se realiza sobre train para aportar evidencia de generalización y evitar optimismo por evaluación sobre entrenamiento.

Métrica	Resultado	Lectura
ROC-AUC Train	0.9980	Capacidad discriminativa en entrenamiento
ROC-AUC CV (5 folds)	0.9621	Generalización interna estable
ROC-AUC Test	0.9588	Alta discriminación en datos no usados para ajuste
Brecha Train-Test	0.0391	Inferior a alerta 0.10
Accuracy	0.9362	Alta exactitud global, pero sensible al desbalance
Precision Moroso	0.9076	Pocas alertas falsas de mora
Recall Moroso	0.6278	Por debajo del objetivo 0.75
F1 Moroso	0.7422	Balance moderado entre precision y recall



Comparación honesta contra baseline. En la comparación de algoritmos del proyecto, Regresión Logística obtuvo ROC-AUC CV ≈0.9457, Random Forest ≈0.9695, XGBoost ≈0.9717 y SVM ≈0.9189. Random Forest fue elegido por su desempeño competitivo, estabilidad e integración con el pipeline; el notebook final vuelve a calcular una Regresión Logística con el mismo preprocesamiento para que la comparación sea reproducible.

2. Matriz de confusión y lectura de negocio



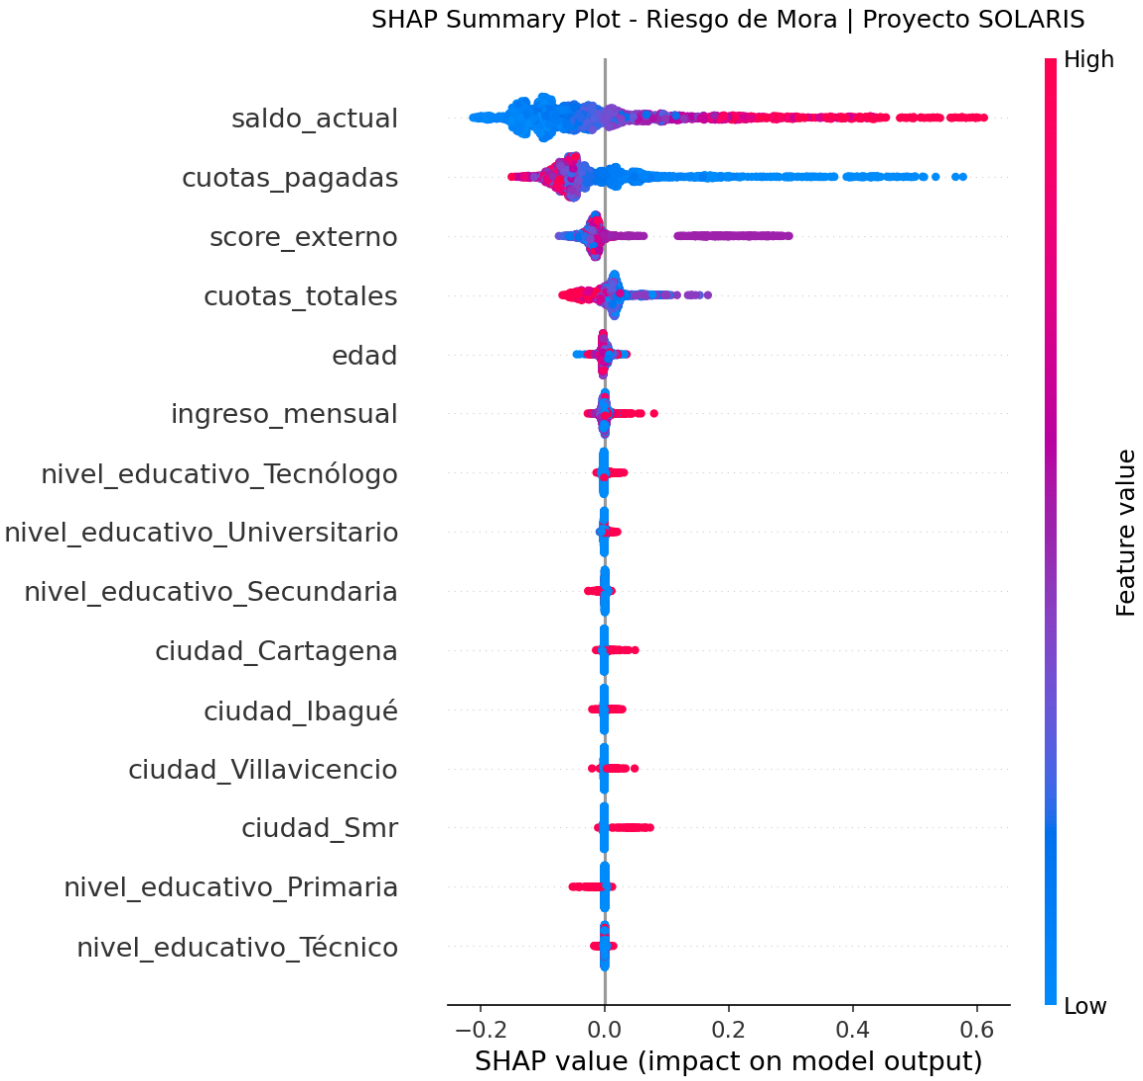
Resultado	Casos	Implicación
TN	2.077	Clientes al día correctamente descartados
FP	23	Clientes al día tratados como riesgo; posible fricción comercial
FN	134	Morosos no detectados; principal riesgo económico y operativo
TP	226	Morosos correctamente identificados

El modelo no debería usarse de forma autónoma para negar crédito o retirar condiciones comerciales. Un falso negativo puede aumentar exposición a cartera; un falso positivo puede afectar injustificadamente la relación con un distribuidor. Por ello el score debe activar revisión y priorización, no una sanción automática.

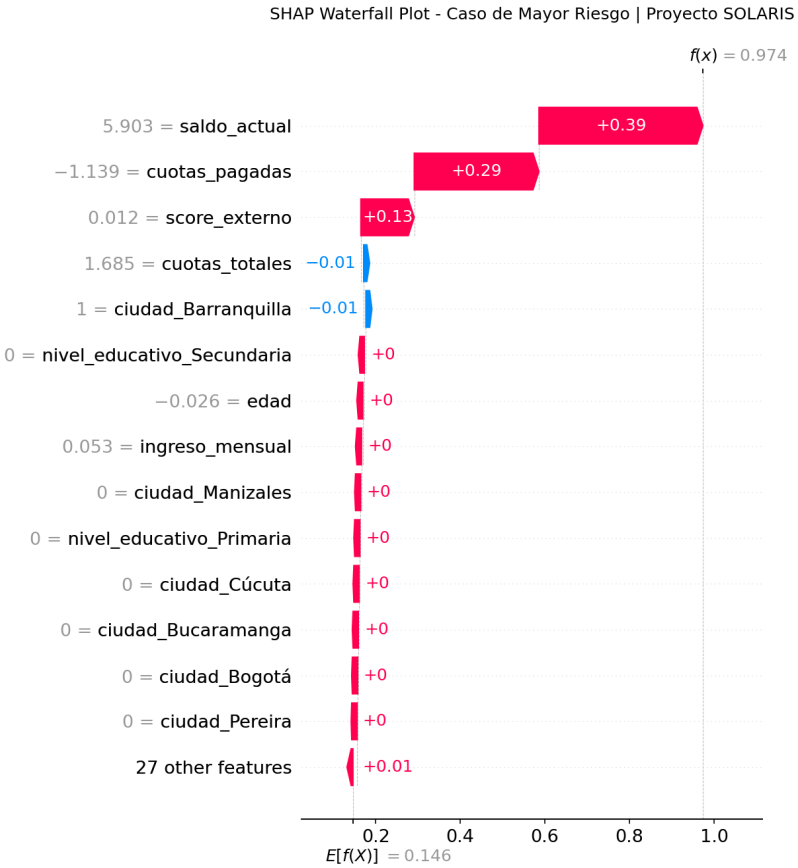
3. Interpretabilidad global - SHAP

El resumen SHAP muestra que las decisiones se apoyan principalmente en variables financieras y de comportamiento. Saldo_actual es el factor más influyente: valores altos elevan el riesgo. Cuotas_pagadas actúa en sentido inverso: pocas cuotas pagadas incrementan el riesgo. Score_externo es el tercer factor clave, pero su composición debe documentarse para descartar proxies no auditados.

3. Interpretabilidad global y local



Lectura de negocio de las 3 variables clave: (1) un saldo pendiente alto incrementa fuertemente el riesgo; (2) un bajo avance en cuotas pagadas aumenta la probabilidad de mora; (3) score_externo aporta señal adicional, pero su procedencia y variables fuente no están documentadas en el dataset.

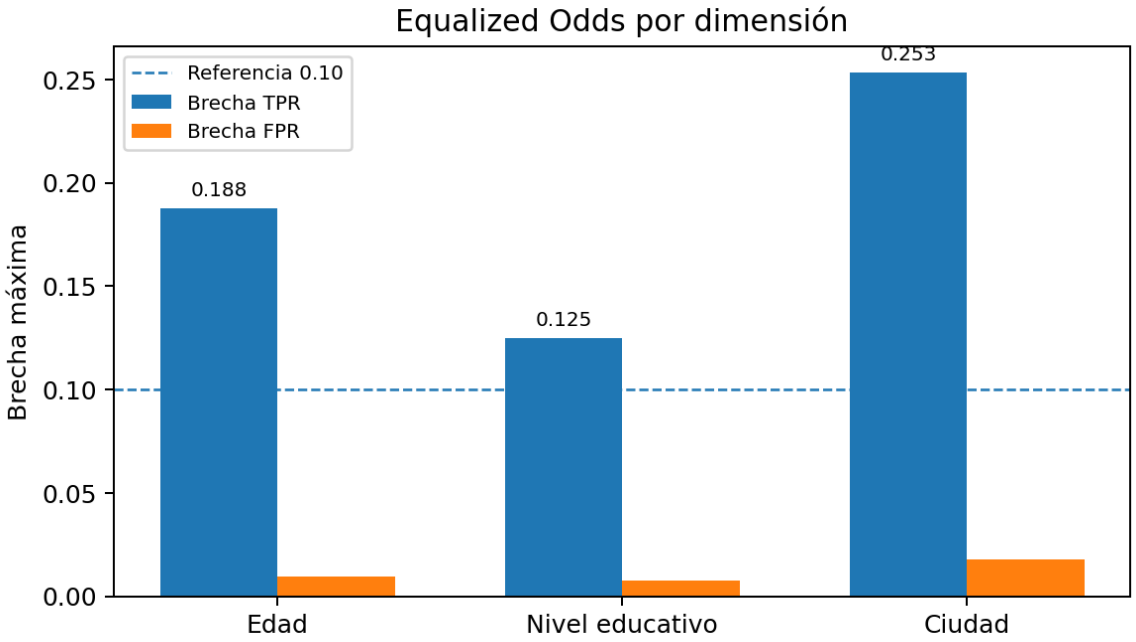


Caso individual: el distribuidor de mayor riesgo obtiene una probabilidad cercana al 97.37%. El saldo_actual y 0 cuotas pagadas son los principales impulsores de la predicción, seguidos por score_externo. El waterfall permite explicar por qué el modelo eleva el caso desde el riesgo base hasta la predicción final.

4. Sesgos y equidad

El dataset no contiene género, raza, etnia ni estrato, por lo que no es posible auditar directamente esas dimensiones. Se evalúan edad, nivel educativo y ciudad como atributos disponibles y posibles proxies. Se usan desempeño por subgrupo, Demographic Parity y Equalized Odds.

Dimensión	Brecha AUC	Brecha DP	Brecha TPR	Brecha FPR	Lectura
Rango de edad	0.0439	0.0467	0.1878	0.0096	Señal EO por sensibilidad
Nivel educativo	0.0395	0.0194	0.1248	0.0076	Señal EO moderada
Ciudad	0.0390	0.0627	0.2533	0.0176	Mayor riesgo de fairness



La principal diferencia está en la TPR por ciudad: Medellín ≈0.7333 y Cartagena ≈0.4800, una brecha de 25.33 puntos porcentuales. No implica por sí sola discriminación causal. Cartagena tiene 25 morosos reales en el subgrupo de prueba y Medellín 30; por tanto, cambios de pocos casos pueden mover la TPR. El hallazgo exige seguimiento, más datos y análisis de causas.

Demographic Parity no supera el umbral de revisión de 0.10; por ciudad la brecha máxima es 0.0627. Esto demuestra por qué una única métrica de fairness no basta: una distribución similar de alertas puede coexistir con distinta capacidad para detectar verdaderos morosos.

5. Riesgos específicos y plan de mitigación

Riesgo	Sev.	Prob.	Evidencia / impacto	Mitigación
Recall insuficiente	Alta	Alta	Recall 0.6278 vs meta 0.75; 134 FN de 360 morosos. Riesgo de cartera no detectada.	Optimizar umbral en validación/CV; class_weight/resampling; costo FN/FP con negocio.
Brecha geográfica	Alta	Media	Brecha TPR ciudad 0.2533. Capacidad desigual de detección según ubicación.	Normalizar ciudad, revisar muestra, reweighting/resampling y monitoreo mensual.
score_externo opaco	Media	Media	3.er factor SHAP (~0.0356); origen no documentado. Riesgo de proxy y baja explicabilidad.	Ficha de procedencia; variables fuente; auditoría con/sin score; aprobación del Data Owner.
Validación temporal limitada	Media	Media	Ventana reciente 136 y split aleatorio, no out-of-time.	Registrar fecha_scoring; test temporal independiente; KS/PSI y performance mensual.

Priorización. Los dos primeros riesgos deben resolverse antes de un uso operacional que afecte condiciones de crédito. Los riesgos de score_externo y validación temporal requieren gobernanza y monitoreo, porque pueden materializarse aun cuando las métricas actuales sean buenas.

6. Propuestas de mejora y sostenibilidad

P1 - Umbral y costo de error (prioridad 1): seleccionar el umbral en validación interna para acercar recall a 0.75 sin degradar la precisión más allá del costo aceptado por Crédito y Cartera.

P2 - Fairness geográfica (prioridad 1): limpiar categorías de ciudad, evaluar representación, reweighting/resampling y reportar TPR/FPR mensualmente.

P3 - Gobernanza de score_externo (prioridad 2): documentar procedencia, variables fuente, actualización y restricciones de uso; repetir desempeño/fairness con y sin esa variable.

P4 - Validación temporal (prioridad 2): conservar fecha de scoring/evento y construir un verdadero holdout out-of-time antes del siguiente cambio de versión.

7. Implicaciones éticas y salvaguardas

La decisión humana afectada es la gestión de riesgo de crédito: qué distribuidores son priorizados para seguimiento y qué casos reciben revisión adicional. El modelo puede beneficiar a FrescaMar al focalizar recursos y anticipar riesgo, pero también puede perjudicar a distribuidores si una predicción incorrecta se transforma automáticamente en restricción de crédito. Existe riesgo de automation bias, discriminación indirecta mediante proxies geográficos o socioeconómicos, opacidad del score_externo y uso secundario de datos fuera del propósito crediticio.

Salvaguardas: revisión humana obligatoria para decisiones adversas; explicación local disponible; canal para corregir datos; control de acceso y registros de auditoría; monitoreo mensual de drift, performance y fairness; documentación de score_externo; y prohibición de usar SOLARIS como único fundamento para negar o retirar crédito. Estas medidas convierten el modelo en apoyo a la decisión y preservan la responsabilidad humana.

8. Recomendación final

DESPLEGAR CON CONDICIONES, únicamente como sistema de apoyo. La evidencia de discriminación global y validación es favorable, pero el recall de mora no cumple la meta de 0.75 y la brecha de Equalized Odds por ciudad es material. Antes de producción se debe recalibrar el umbral en validación, revisar la disparidad geográfica, documentar score_externo y formalizar revisión humana y monitoreo. Hasta entonces, el modelo puede utilizarse para priorización interna, no para decisiones automáticas finales.

Casos en los que NO debe usarse

No debe utilizarse como decisor autónomo de aprobación/rechazo; fuera de la población objetivo de distribuidores comparable a la muestra; cuando faltan o cambian de definición variables críticas; tras detectar drift o caída de recall/fairness fuera de umbrales; ni para inferir características sensibles que no forman parte del propósito del modelo.

Referencias

O'Neil, C. (2016). *Weapons of Math Destruction*. Crown. | NIST (2023). *AI Risk Management Framework 1.0*. | Naciones Unidas. ODS 9: Industria, Innovación e Infraestructura. | Material del Módulo 4: Evaluación crítica, fairness y responsabilidad algorítmica.