INFORME DE EVALUACIÓN CRÍTICA

Validación, interpretabilidad, sesgos, riesgos e impacto ético

Proyecto: SOLARIS - FrescaMar S.A.S.

Módulo: 4 · Evaluación crítica

Ana Sofía Herrera Sánchez

Resumen ejecutivo

SOLARIS estima el riesgo de mora de distribuidores de FrescaMar S.A.S. El pipeline final utiliza Random Forest con preprocesamiento integrado y un split estratificado 80/20 con random_state=42. En prueba alcanza ROC-AUC 0.9588, Accuracy 0.9362, Precision Moroso 0.9076, Recall Moroso 0.6278 y F1 0.7422. La brecha ROC-AUC train-test es 0.0391, inferior a la alerta interna de 0.10. No obstante, el recall queda por debajo del objetivo de negocio de 0.75, por lo que el modelo aún deja pasar una fracción relevante de morosos reales.

La validación cruzada reproducida sobre entrenamiento obtiene ROC-AUC medio 0.9615 (desviación 0.0070) y el baseline de Regresión Logística alcanza 0.9225 en CV y 0.9241 en test. La auditoría de equidad no detecta alertas en Demographic Parity ni brechas de AUC superiores a 0.05, pero Equalized Odds muestra diferencias de sensibilidad: 18.78 p.p. por edad, 12.47 p.p. por educación y 25.33 p.p. por ciudad. SHAP confirma que saldo_actual, cuotas_pagadas y score_externo dominan la decisión. El modelo puede aportar valor como herramienta de priorización si se ajusta el umbral con validación interna, se revisa la disparidad geográfica, se documenta score_externo y se mantiene supervisión humana.

El modelo discrimina bien y supera claramente al baseline, pero no debe automatizar decisiones adversas mientras el recall de morosos permanezca por debajo del objetivo y exista una brecha material de Equalized Odds por ciudad.

1. Validación técnica robusta

Las métricas operativas se reportan sobre el conjunto de prueba de 2.460 registros, aislado del entrenamiento. La validación cruzada se realiza exclusivamente sobre train para aportar evidencia de generalización y evitar optimismo por evaluación sobre datos usados para ajustar el modelo.

Métrica	Resultado	Lectura
ROC-AUC Train	0.9980	Capacidad discriminativa en entrenamiento

ROC-AUC CV (5 folds, reproducida)	0.9615 ± 0.0070	Generalización interna estable
ROC-AUC Test	0.9588	Alta discriminación en datos no usados para ajuste
Brecha Train-Test	0.0391	Inferior a alerta interna 0.10
Accuracy	0.9362	Alta exactitud global, sensible al desbalance
Precision Moroso	0.9076	Pocas alertas falsas de mora
Recall Moroso	0.6278	Por debajo del objetivo de negocio 0.75
F1 Moroso	0.7422	Balance moderado entre precision y recall

Análisis de hiperparámetros

La optimización original se realizó con GridSearchCV sobre 24 combinaciones y 5 folds (120 ajustes), usando ROC-AUC como métrica de selección. El mejor pipeline quedó regularizado mediante profundidad máxima y tamaño mínimo de hoja; posteriormente se volvió a validar con un StratifiedKFold de 5 folds con shuffle=True para el entregable final.

Elemento	Valor final / rango evaluado
n_estimators	400 (evaluados: 200, 400)
max_depth	20 (evaluados: None, 10, 20)
min_samples_split	2 (evaluados: 2, 5)
min_samples_leaf	2 (evaluados: 1, 2)
ROC-AUC de selección GridSearchCV	0.9621
ROC-AUC CV reproducida en notebook final	0.9615

Comparación honesta contra baseline

Modelo	ROC-AUC CV	ROC-AUC Test	Precision	Recall	F1
Regresión Logística (baseline)	0.9225	0.9241	0.8230	0.5167	0.6348
Random Forest SOLARIS	0.9615	0.9588	0.9076	0.6278	0.7422

El Random Forest supera al baseline de forma consistente tanto en validación cruzada como en test, especialmente en ROC-AUC, recall y F1 de la clase Moroso. Por ello se justifica mantenerlo como modelo principal, aunque su recall actual aún no satisface el objetivo de negocio.

2. Matriz de confusión y lectura de negocio

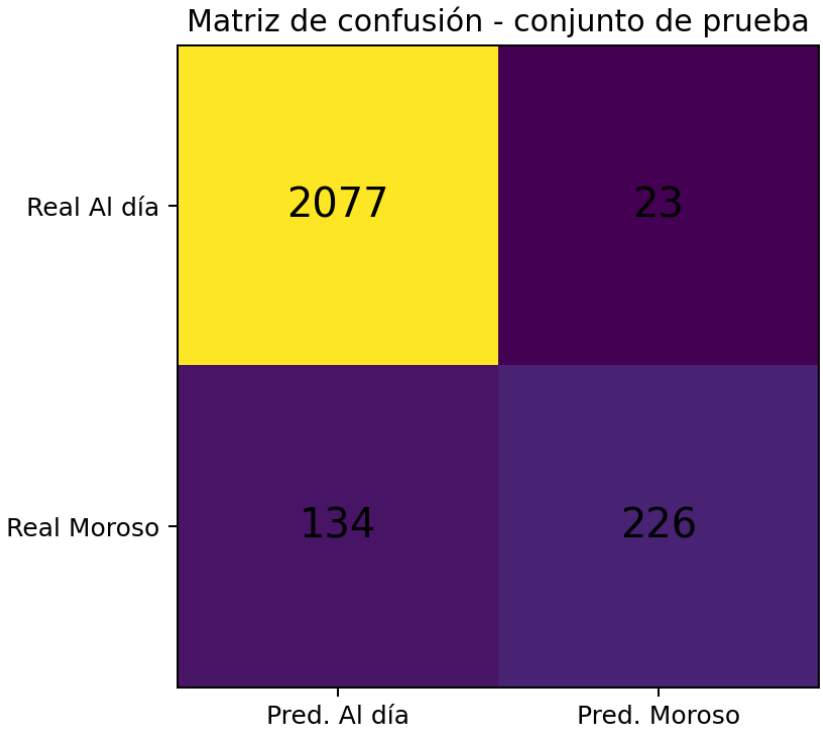


Figura 1. Matriz de confusión del conjunto de prueba.

Resultado	Casos	Implicación
TN	2.077	Clientes al día correctamente descartados
FP	23	Clientes al día tratados como riesgo; posible fricción comercial
FN	134	Morosos no detectados; principal riesgo económico y operativo
TP	226	Morosos correctamente identificados

134 de 360 morosos reales no son detectados. Esto equivale a 37.2% de los casos de mora del test y explica por qué el recall (62.78%) es el principal límite operativo del modelo.

El modelo no debería usarse de forma autónoma para negar crédito o retirar condiciones comerciales. Un falso negativo puede aumentar la exposición a cartera; un falso positivo puede afectar injustificadamente la relación con un distribuidor. Por ello el score debe activar revisión y priorización, no una sanción automática.

Casos en los que no debe usarse: fuera de la población objetivo de distribuidores comparable a la muestra; cuando faltan o cambian de definición variables críticas; después de detectar drift o caída de recall/fairness fuera de umbrales; ni para inferir características sensibles que no forman parte del propósito crediticio.

3. Interpretabilidad global - SHAP

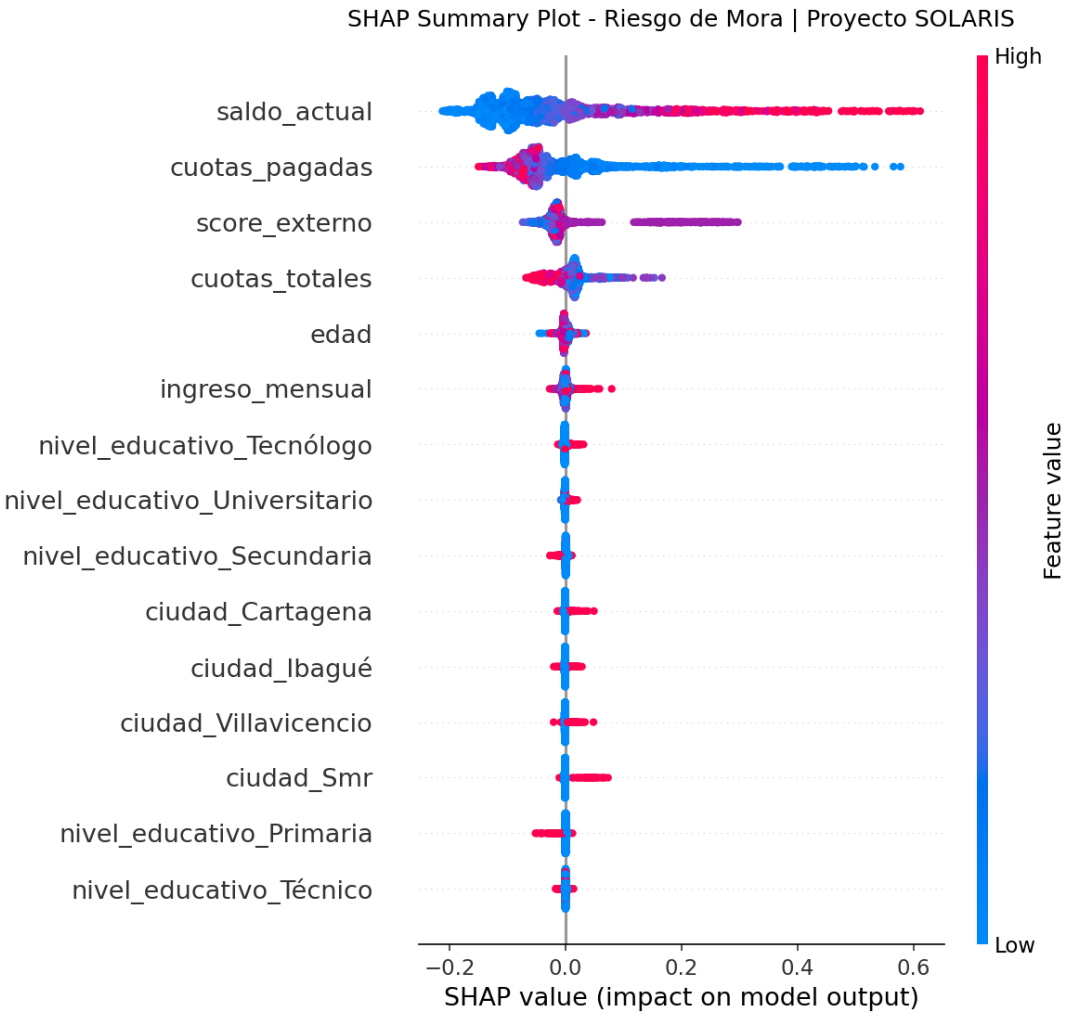


Figura 2. SHAP summary plot del modelo SOLARIS.

Las tres variables más influyentes son saldo_actual, cuotas_pagadas y score_externo. Saldo_actual es el factor dominante: valores altos desplazan la predicción hacia mayor riesgo. Cuotas_pagadas actúa en sentido inverso: pocas cuotas pagadas elevan la probabilidad de mora. Score_externo aporta señal

adicional, pero su composición no está documentada en el dataset y debe auditarse para descartar proxies no controlados.

Variable	Importancia SHAP media	Interpretación de negocio
saldo_actual	0.1088	Un saldo pendiente alto incrementa fuertemente el riesgo estimado.
cuotas_pagadas	0.0720	Un bajo avance de pagos eleva la probabilidad de mora.
score_externo	0.0356	Aporta señal externa relevante; requiere trazabilidad de su procedencia.

3.1 Interpretabilidad local - caso individual

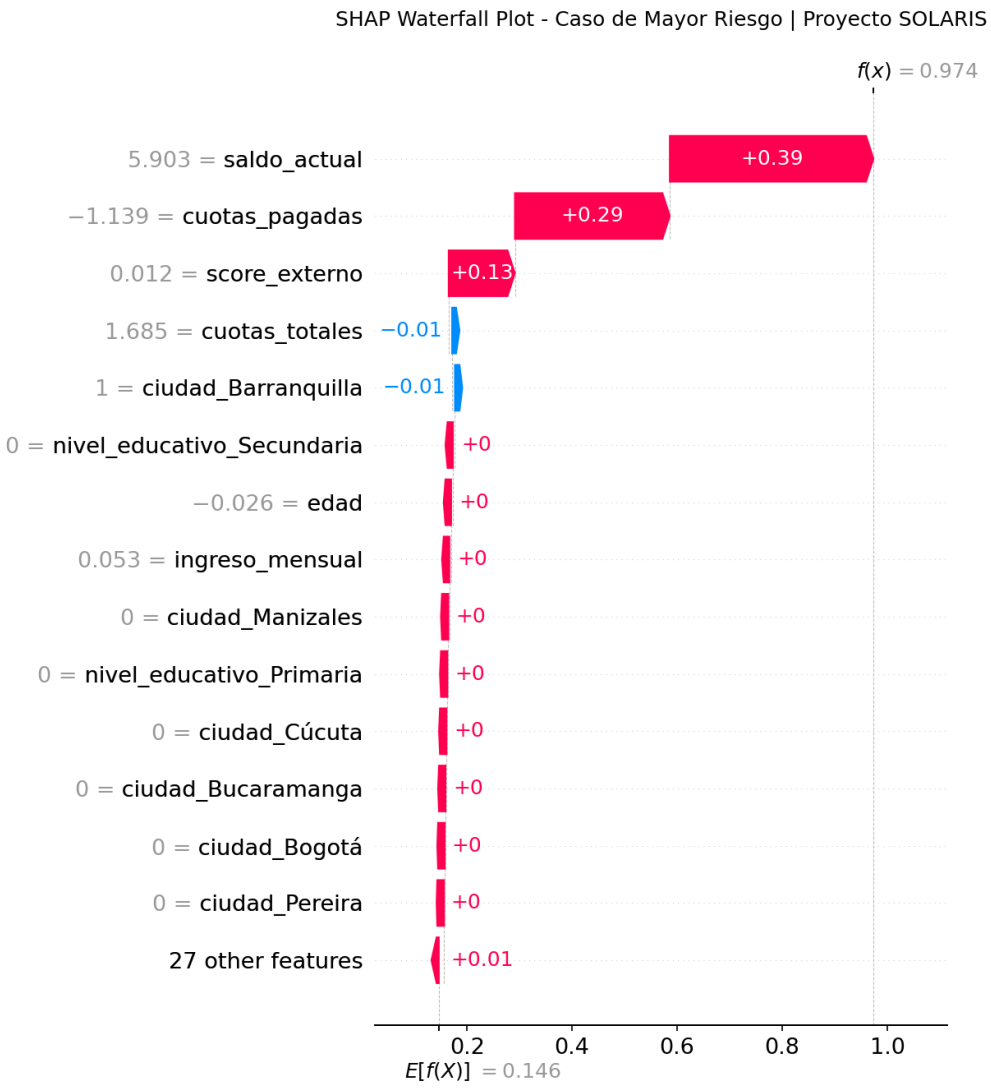


Figura 3. SHAP waterfall del caso de mayor riesgo.

El distribuidor de mayor riesgo obtiene una probabilidad cercana a 97.4%. El saldo_actual y la ausencia de cuotas pagadas son los principales impulsores de la predicción, seguidos por score_externo. El waterfall permite mostrar cómo el caso se desplaza desde el riesgo base hasta la predicción final, facilitando una explicación verificable a un analista humano.

La explicación SHAP ayuda a comprender la predicción, pero no transforma correlaciones en causas. La decisión final debe conservar contexto comercial y revisión humana.

4. Sesgos y equidad

El dataset no contiene género, raza, etnia ni estrato, por lo que no es posible auditar directamente esas dimensiones. Se evalúan rango de edad, nivel educativo y ciudad como atributos disponibles y posibles proxies. Se usan desempeño por subgrupo, Demographic Parity y Equalized Odds.

Dimensión	Brecha AUC	Brecha DP	Brecha TPR	Brecha FPR	Lectura
Rango de edad	0.0439	0.0467	0.1878	0.0096	Señal EO por sensibilidad
Nivel educativo	0.0395	0.0194	0.1247	0.0076	Señal EO moderada
Ciudad	0.0390	0.0628	0.2533	0.0176	Mayor riesgo de fairness

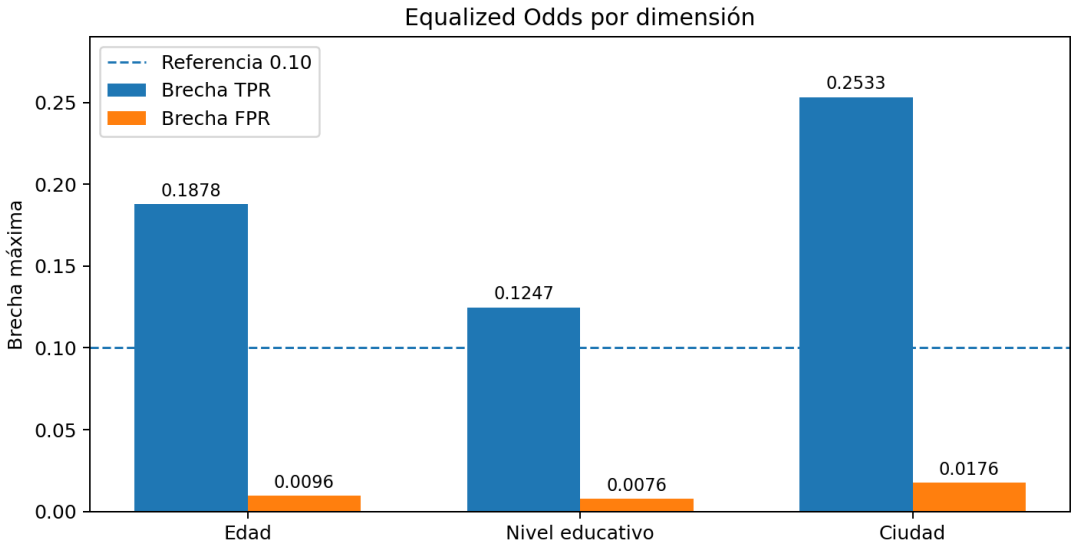


Figura 4. Brechas de Equalized Odds por dimensión.

La principal diferencia está en la TPR por ciudad: Medellín ≈0.7333 y Cartagena ≈0.4800, una brecha de 25.33 puntos porcentuales. No implica por sí sola discriminación causal. Cartagena tiene 25 morosos reales en el subgrupo de prueba y Medellín 30; por tanto, cambios de pocos casos pueden mover la TPR. El hallazgo exige seguimiento, más datos y análisis de causas.

Demographic Parity no supera el umbral de revisión de 0.10; por ciudad la brecha máxima es 0.0628. Esto demuestra por qué una única métrica de fairness no basta: una distribución similar de alertas puede coexistir con distinta capacidad para detectar verdaderos morosos.

5. Riesgos específicos y propuestas de mejora

Riesgo	Sev.	Prob.	Evidencia / impacto	Mitigación realizable
Recall insuficiente	Alta	Alta	Recall 0.6278 vs meta 0.75; 134 FN de 360 morosos. Riesgo de cartera no detectada.	Optimizar umbral en validación/CV; evaluar class_weight o resampling; acordar costo FN/FP con negocio.
Brecha geográfica	Alta	Media	Brecha TPR ciudad 0.2533. Capacidad desigual de detección según ubicación.	Normalizar ciudad, revisar muestra, reweighting/resampling y monitoreo mensual de TPR/FPR.
score_externo opaco	Media	Media	3.er factor SHAP (~0.0356); origen no documentado. Riesgo de proxy y baja explicabilidad.	Ficha de procedencia, variables fuente, auditoría con/sin score y aprobación del Data Owner.
Validación temporal limitada	Media	Media	Ventana reciente 136 y split aleatorio, no out-of-time.	Registrar fecha_scoring; test temporal independiente; KS/PSI y desempeño mensual.

Priorización de mejora y sostenibilidad

- P1 - Umbral y costo de error: seleccionar el umbral en validación interna para acercar recall a 0.75 sin degradar la precisión más allá del costo aceptado por Crédito y Cartera.
- P2 - Fairness geográfica: limpiar categorías de ciudad, evaluar representación, reweighting/resampling y reportar TPR/FPR mensualmente.
- P3 - Gobernanza de score_externo: documentar procedencia, variables fuente, actualización y restricciones de uso; repetir desempeño y fairness con y sin esa variable.
- P4 - Validación temporal: conservar fecha de scoring/evento y construir un holdout out-of-time antes del siguiente cambio de versión.

Los dos primeros riesgos deben resolverse antes de un uso operacional que afecte condiciones de crédito. Los riesgos de score_externo y validación temporal requieren gobernanza y monitoreo continuo porque pueden materializarse aun cuando las métricas actuales sean favorables.

6. Implicaciones éticas y salvaguardas

La decisión humana afectada es la gestión de riesgo de crédito: qué distribuidores son priorizados para seguimiento y qué casos reciben revisión adicional. El modelo puede beneficiar a FrescaMar al focalizar recursos y anticipar riesgo, pero también puede perjudicar a distribuidores si una predicción incorrecta se transforma automáticamente en restricción de crédito. Existe riesgo de automation bias, discriminación indirecta mediante proxies geográficos o socioeconómicos, opacidad del score_externo y uso secundario de datos fuera del propósito crediticio.

- Revisión humana obligatoria para decisiones adversas; el modelo no debe ser el único fundamento para negar o retirar crédito.
- Explicación local disponible y canal para corregir datos o impugnar una decisión basada en información errónea.
- Control de acceso, finalidad de uso, registros de auditoría y trazabilidad del score_externo.
- Monitoreo mensual de drift, desempeño y fairness, con protocolo de escalamiento cuando se superen umbrales.

7. Recomendación final

DESPLEGAR CON CONDICIONES, únicamente como sistema de apoyo. La evidencia de capacidad discriminativa global y de validación es favorable, pero el recall de mora no cumple la meta de 0.75 y la brecha de Equalized Odds por ciudad es material. Antes de producción se debe recalibrar el umbral en validación, revisar la disparidad geográfica, documentar score_externo y formalizar revisión humana y monitoreo. Hasta entonces, el modelo puede utilizarse para priorización interna, no para decisiones automáticas finales.

Referencias

- O’Neil, C. (2016). Weapons of Math Destruction. Crown.
- NIST (2023). AI Risk Management Framework 1.0.
- Naciones Unidas. Objetivos de Desarrollo Sostenible: ODS 9 y ODS 10.
- Universidad de La Sabana. Guía de actividad - Unidad 4.
- Material QUANTUM ANALYTICS, Módulo 4: evaluación crítica, fairness y responsabilidad algorítmica.